

**LAPORAN PRAKTIKUM
BIG DATA ANALYTICS KLASIFIKASI CIFAR-10
MENGUNAKAN GRAYSCALE NTSC CNN + SVM**

Dosen Pengampu:

Bayu Adi Nugroho, Ph.D



**UIN SUNAN AMPEL
S U R A B A Y A**

Disusun Oleh:

Afrizal Dwi Ahmad - 0901062400

**PROGRAM STUDI SISTEM INFORMASI
UNIVERSITAS ISLAM NEGERI SUNAN AMPEL SURABAYA
2026**

1. Spesifikasi Perangkat

Pelaksanaan eksperimen menggunakan perangkat dan environment berikut. GPU NVIDIA juga terdeteksi pada output notebook saat menjalankan TensorFlow. Spesifikasi CPU, RAM, dan sistem operasi sesuai perangkat praktikum yang digunakan.

Komponen	Spesifikasi
Prosesor	Intel Core i5-12450HX
GPU	NVIDIA GeForce RTX 3050 Laptop GPU, 6 GB VRAM
RAM	32 GB
Sistem operasi	Kubuntu 26.04.1 LTS (Linux)
Environment	Anaconda, environment envGPU
Framework dan library	TensorFlow/Keras; NumPy; scikit-learn; joblib; Matplotlib (pada Testing)
Dataset	CIFAR-10, 10 kelas; gambar 32×32 piksel
Pembagian data	50.000 gambar official training; 10.000 official test; development split 40.000 training dan 10.000 validation
Seed	30092026

Seluruh hasil numerik dalam laporan ini diambil dari output eksekusi notebook yang dikumpulkan. Ketika suatu skor tidak dicetak atau tidak tersedia, laporan tidak menambahkan nilai perkiraan.

2. Dataset dan Konversi Grayscale

Dataset CIFAR-10 mempunyai 50.000 official training images dan 10.000 official test images. Development split terdiri atas 40.000 training dan 10.000 validation, dengan seed 30092026. Gambar awal RGB $32 \times 32 \times 3$ dikonversi menjadi $32 \times 32 \times 1$ sehingga informasi warna tidak lagi dipertahankan dalam tiga channel terpisah.

Potongan kode asli: transformasi Grayscale NTSC (NTSC Training(4).ipynb, prepare_images)

```
if variant == "ntsc":
    weights = np.array([0.299, 0.587, 0.114], dtype=np.float32)
    return np.sum(x * weights, axis=-1, keepdims=True)
```

Untuk AVG, nilai grayscale dihitung dari rata-rata tiga channel RGB. Untuk NTSC, pembobotan 0,299, 0,587, dan 0,114 mengikuti rumus yang digunakan pada fungsi prepare_images. Semua channel telah dinormalisasi ke 0–1 sebelum perhitungan.

3. Arsitektur CNN dan Pelatihan

Custom Residual CNN menggunakan input $32 \times 32 \times 1$, residual stages 64, 128, dan 256, serta shortcut connections. GlobalAveragePooling2D dan Dropout mengawali Dense(512) bernama embedding. Layer output Softmax menghasilkan 10 probabilitas kelas. Data augmentation terdiri dari RandomCrop dan RandomFlip.

Potongan kode asli: residual stages dan output CNN

```
for filters, first_stride in ((64, 1), (128, 2), (256, 2)):
    x = residual_block(x, filters, first_stride)
    x = residual_block(x, filters)
x = tf.keras.layers.GlobalAveragePooling2D()(x)
x = tf.keras.layers.Dropout(dropout)(x)
embedding = tf.keras.layers.Dense(512, activation="relu", dtype="float32", name="embedding")(x)
outputs = tf.keras.layers.Dense(10, activation="softmax", dtype="float32")(embedding)
return tf.keras.Model(inputs, outputs)
```

GridSearchCV CNN melakukan screening learning rate dengan 20 epochs sebelum pelatihan final. CNN final menggunakan AdamW, CosineDecay, batch size 64, maximum 150 epochs, ModelCheckpoint terbaik berdasarkan val_accuracy, dan EarlyStopping patience 20.

Tahap	Nilai
Best CNN GridSearchCV validation	88,41%
CNN learning rate terpilih	0,001
Epoch CNN final	150
Best checkpoint epoch	137
Best CNN validation accuracy	91,16%
Durasi full CNN training	8.925,49 detik

4. Feature Extraction dan SVM

Feature extraction menggunakan layer embedding berukuran 512. Vektor training tersimpan sebagai .npz. Classifier standalone memakai Pipeline StandardScaler → Normalizer → RBF SVC. PredefinedSplit pada GridSearchCV menjaga pemisahan 40.000 development training dari 10.000 development validation.

Potongan kode asli: Pipeline dan parameter GridSearchCV

```
svm_pipeline = Pipeline(
    steps=[
        ("scale", StandardScaler()),
        ("norm", Normalizer()),
        ("svc", SVC(kernel="rbf", cache_size=512, random_state=SEED, verbose=1)),
    ]
)
svm_grid = GridSearchCV(
    estimator=svm_pipeline,
    param_grid={
        "svc__C": [1, 10],
        "svc__gamma": ["scale", 0.001],
    },

```

Indikator	Hasil
Kombinasi SVM	4
Parameter C terpilih	1
Parameter gamma	scale
SVM validation accuracy	90,92%
SVM official-test accuracy	90,64%
Official-test macro-F1	90,6286%
Fitting terakhir	40.000 development training features

5. Official Test dan Classification Report

NTSC Testing(4).ipynb memuat model CNN dan SVM tersimpan, mengekstrak embedding dari 10.000 official-test images, lalu menghitung accuracy, macro-F1, classification_report, dan confusion matrix. SVM memperoleh accuracy 90,64% (9.064/10.000 prediksi benar).

5.1 Classification report Grayscale NTSC + SVM


Kelas	Precision	Recall	F1-score
airplane	0,92	0,92	0,92
automobile	0,95	0,96	0,96

bird	0,87	0,86	0,87
cat	0,83	0,81	0,82
deer	0,86	0,90	0,88
dog	0,86	0,87	0,86
frog	0,93	0,93	0,93
horse	0,94	0,93	0,93
ship	0,95	0,95	0,95
truck	0,95	0,94	0,95

Setiap kelas memiliki support 1.000 pada official test CIFAR-10. Angka dalam tabel mengikuti tampilan classification_report yang tercatat pada notebook, sehingga tingkat pembulatan antarbagian dapat berbeda.

6. Confusion Matrix dari Output Notebook

Gambar 1. Confusion matrix Grayscale NTSC + SVM



File model dan fitur seperti .keras, .joblib, serta .npz merupakan artefak yang dipakai atau dihasilkan oleh notebook. Berkas tersebut tidak termasuk dalam paket 12 notebook dan 4 laporan kecuali dikirim secara terpisah.

7. Analisis Mengapa Accuracy Belum Mencapai 95%

Official-test accuracy 90,64% berarti 9.064/10.000 prediksi benar, masih kurang 436 prediksi untuk mencapai 9.500. Skor validation 90,92% dan official test 90,64% terpaut 0,28 poin persentase.

Classification_report menunjukkan kelas cat F1-score 0,82 dan dog 0,86, sedangkan automobile 0,96. Confusion matrix menunjukkan kesalahan antar-kelas tertentu, khususnya cat dan dog. Pola ini menggambarkan error yang teramati, bukan bukti bahwa masalah hanya berasal dari satu komponen.

Transformasi NTSC memakai weighted luminance, yang mempertahankan bobot berbeda untuk channel RGB tetapi tetap mereduksi tiga channel menjadi satu. Informasi chromatic yang tidak tersimpan dalam grayscale mungkin membantu membedakan sebagian objek; perlu eksperimen terkontrol untuk membuktikan besarnya efek.

SVM dengan embedding CNN menghasilkan performa lebih baik daripada beberapa nilai awal training, tetapi pencarian hyperparameter terbatas dan CNN tidak mencapai separasi kelas yang cukup pada official test. Hal itu sejalan dengan hasil, meskipun penyebab kuantitatif tiap kegagalan tidak bisa dipastikan.

Kesimpulan: experiment Grayscale NTSC telah selesai diuji, official-test accuracy 90,64%, dan syarat $\geq 95\%$ belum tercapai.